操作系统　Operation System

第二章 系统引导

内容提要

- 计算机的启动过程（X86）
- X86下Linux系统引导过程

Bootstraping

- Bootstrap：拔靴带/引导程序
  - 吹牛大王历险记：**pull oneself up by one's bootstraps**
  - Baron Munchausen pulls himself and his horse out of a swamp by his hair.

underwater

riding the cannon ball

flying with ducks

We are not alone

- 早期汽车的启动过程：
  - 引擎需要对压缩的燃料和空气点火后才能工作
  - 只有引擎工作了才能压缩燃料空气
  - 矛盾?
- 现在汽车的启动过程
  - 借助外力：人力、电机

启动，是一个很“纠结”的过程

- 现代计算机 —— 硬件 + 软件
- 启动的矛盾：
  - 一方面：必须通过程序控制使得计算机硬件进入特定工作状态（硬件启动依赖软件）
  - 另一方面：程序必须运行在设置好工作模式的硬件环境上（软件运行依赖硬件）
- 因此：启动前硬件状态必须假设在一个最安全、通用，因此也是功能最弱的状态，需要逐步设置硬件，以提升硬件环境能力
- OS启动是一个逐步释放系统灵活性的过程

X86 启动过程（与OS无关）

1. Turn on
2. CPU jump to physical address of BIOS (0xFFFF0) （Intel 80386）
3. BIOS runs POST (Power-On Self Test)
4. Find bootable devices
5. Loads boot sector from MBR
6. BIOS yields control to OS BootLoader

第一阶段

第二阶段

BIOS (Basic Input/Output System)

- BIOS设置程序是被固化到电脑主板上的ROM芯片中的一组程序，其主要功能是为电脑提供最底层地、最直接地硬件设置和控制。BIOS通常与硬件系统集成在一起（在计算机主板的ROM或EEPROM中），所以也被称为固件。

BIOS on board

BIOS on screen

BIOS

- BIOS程序存放于一个断电后内容不会丢失的只读存储器中；系统过电或被重置（reset）时，处理器要执行第一条指令的地址会被定位到BIOS的存储器中，让初始化程序开始运行。
- 在X86系统中，CPU加电后将跳转到BIOS的固定物理地址0xFFFF0。

(Intel 80386)

启动第一步——加载BIOS

- 当打开计算机电源，计算机会首先加载BIOS信息。BIOS中包含了CPU的相关信息、设备启动顺序信息、硬盘信息、内存信息、时钟信息、PnP特性等等。在此之后，计算机心里就有谱了，知道应该去读取哪个硬件设备了。

BIOS

硬件自检（Power-On Self-Test）

- BIOS代码包含诊断功能，以保证某些重要硬件组件，像是键盘、磁盘设备、输出输入端口等等，可以正常运作且正确地初始化。

如果硬件出现问题，主板会发出不同含义的蜂鸣，启动中止。如果没有问题，屏幕就会显示出CPU、内存、硬盘等信息。

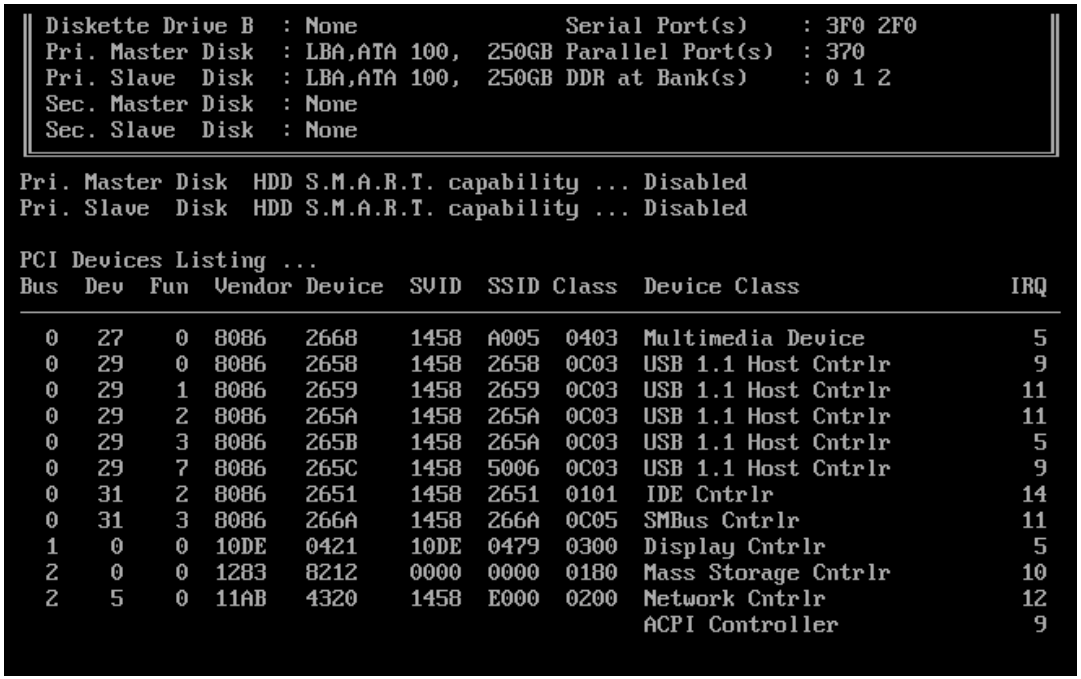

BIOS

读取启动顺序（Boot Sequeue）

- 现代的BIOS可以让用户选择由哪个设备引导电脑，如光盘驱动器、硬盘、软盘、USB U盘等等。这项功能对于安装操作系统、以CD引导电脑、以及改变电脑找寻开机媒体的顺序特别有用。

打开**BIOS**的操作界面，里面有一项就是"设定启动顺序"。

小知识

- 磁道（track）
  - 盘片上以盘片中心为圆心，不同半径的同心圆。
- 扇区（Sector）
  - 盘片被分成许多扇形的区域
- 柱面（Cylinder)
  - 硬盘中，不同盘片相同半径的磁道所组成的圆柱。
- 每个磁盘有两个面，每个面都有一个磁头(Head)。
- 磁盘按照C-H-S规则寻址

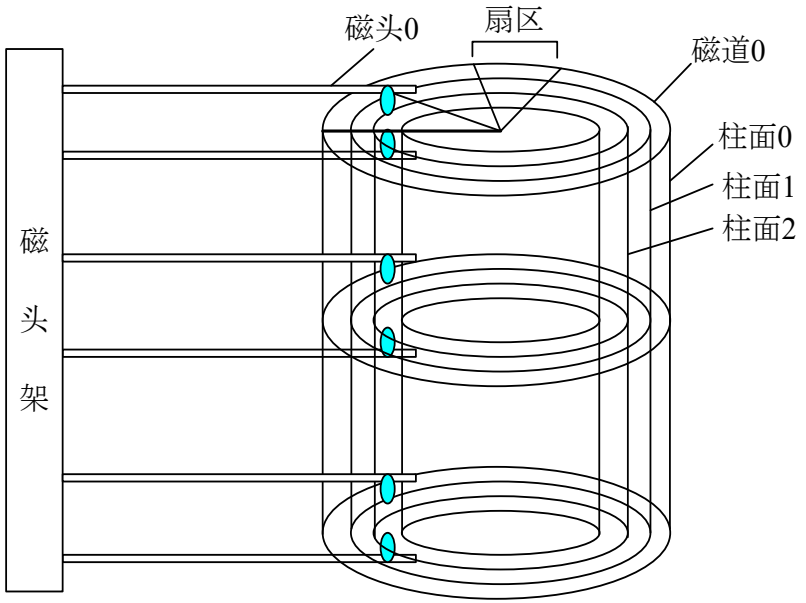

BIOS的问题

- 16位~20位实模式寻址能力
- 实现结构、可移植性
  - 磁盘的Cylinder-Head-Sector （CHS）寻址
  - 一个扇区512byte，MBR只有32位来存取扇区数
  - $2^{32} * 512$ byte = 2199023 MB = 2.19 TB
- 问题根源
  - 历史的局限性、向前兼容的压力
    - 支持遗留软件：老设备驱动等
  - 经典≈（成熟、稳定、共识），来之不易，维持整个产业生态正常运转的必要Tradeoff
  - IT发展太快，对“历史局限”的继承，导致改变成本越来越高。——“另起炉灶”（UEFI）来解决。

UEFI——统一可扩展固件接口

- Unified Extensible Firmware Interface
  - 2000年提出，Intel组建生态
- 功能特性
  - 支持从超过2TB的大容量硬盘引导 (GUID Partition Table，GPT分区) (硬件支持)
  - CPU-independent architecture(可移植性)
  - CPU-independent drivers (可移植性)
  - Flexible pre-OS environment, including network capability (硬件支持)
  - Modular design (可移植性)

https://en.wikipedia.org/wiki/Unified_Extensible_Firmware_Interface#cite_note-note1-15

UEFI和BIOS的比较

二者显著的区别是:

- EFI是用模块化，C语言风格的参数堆栈传递方式，动态链接的形式构建的系统，较BIOS而言更易于实现，容错和纠错特性更强，缩短了系统研发的时间。
- 它运行于32位或64位模式，乃至未来增强的处理器模式下，突破传统BIOS的16位代码的寻址能力，达到处理器的最大寻址。

启动第二步——读取MBR

- 硬盘上第0磁头第0磁道第一个扇区被称为MBR，也就是Master Boot Record，即主引导记录，它的大小是512字节，别看地方不大，可里面却存放了预启动信息、分区表信息。

装入MBR

- MBR的全称是Master Boot Record（主引导记录），MBR早在1983年IBM PC DOS 2.0中就已经提出。之所以叫“主引导记录”，是因为它是存在于驱动器开始部分的一个特殊的启动扇区。
- 这个扇区包含了已安装的操作系统的启动加载器(BootLoader)和驱动器的逻辑分区信息。

MBR的结构

- MBR(Master Boot Record)主引导记录包含两部分的内容，前446字节为启动代码及数据；
- 之后则是分区表（DPT），分区表由四个分区项组成，每个分区项数据为16字节，记录了启动时需要的分区参数。这64个字节分布在MBR的第447-510字节。
- 后面紧接着两个字节AA和55被称为魔数(Magic Number), BOIS读取MBR的时候总是检查最后是不是有这两个magic number ,如果没有就被认为是一个没有被分区的硬盘。

MBR (Master Boot Record)

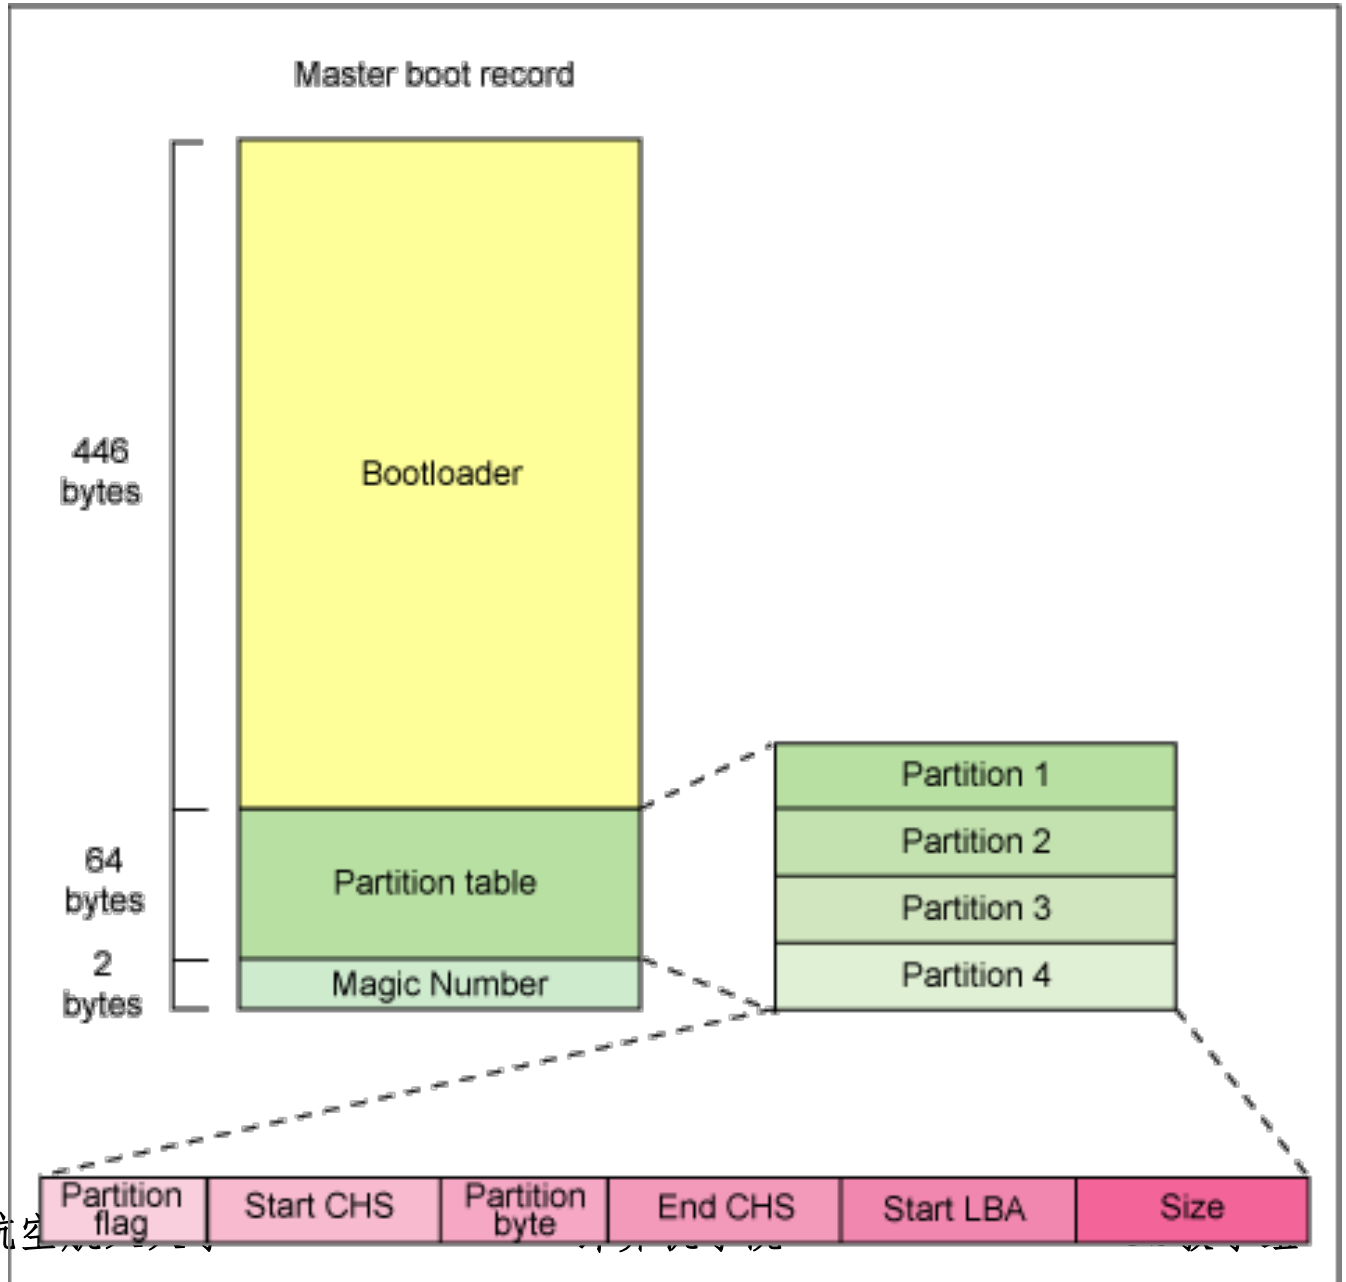

存贮字节位	内容及含义
第1字节	引导标志。若值为80H表示活动分区，若值为00H表示非活动分区。
第2、3、4字节	本分区的起始磁头号、扇区号、柱面号。其中： 磁头号——第2字节；扇区号——第3字节的低6位； 柱面号——为第3字节高2位+第4字节8位。
第5字节	分区类型符。 00H——表示该分区未用（即没有指定）； 06H——FAT16基本分区； 0BH——FAT32基本分区； 05H——扩展分区； 07H——NTFS分区； 0FH——（LBA模式）扩展分区（83H为Linux分区等）。
第6、7、8字节	本分区的结束磁头号、扇区号、柱面号。其中： 磁头号——第6字节；扇区号——第7字节的低6位； 柱面号——第7字节的高2位+第8字节。
第9-12字节	本分区之前已用了的扇区数。
第13,14,15,16字节	本分区的总扇区数。

MBR

- 由于MBR的限制 只能有4个主分区，系统必须装在主分区上面。
- 硬盘分区有三种，主磁盘分区、扩展磁盘分区、逻辑分区。
- 一个硬盘主分区至少有1个，最多4个，扩展分区可以没有，最多1个。且主分区+扩展分区总共不能超过4个。逻辑分区可以有若干个。
- 主分区只能有一个是活动的（active），其余为inactive。

MBR

- 分出主分区后，其余的部分可以分成扩展分区，一般是剩下的部分全部分成扩展分区。
- 扩展分区不能直接使用，必须分成若干逻辑分区。所有的逻辑分区都是扩展分区的一部分。

硬盘的容量＝主分区的容量＋扩展分区的容量

扩展分区的容量＝各个逻辑分区的容量之和

内容提要

- 计算机的启动过程（X86）
- X86下Linux系统引导过程

How Linux boot?

- 逐级引导、逐步释放灵活性

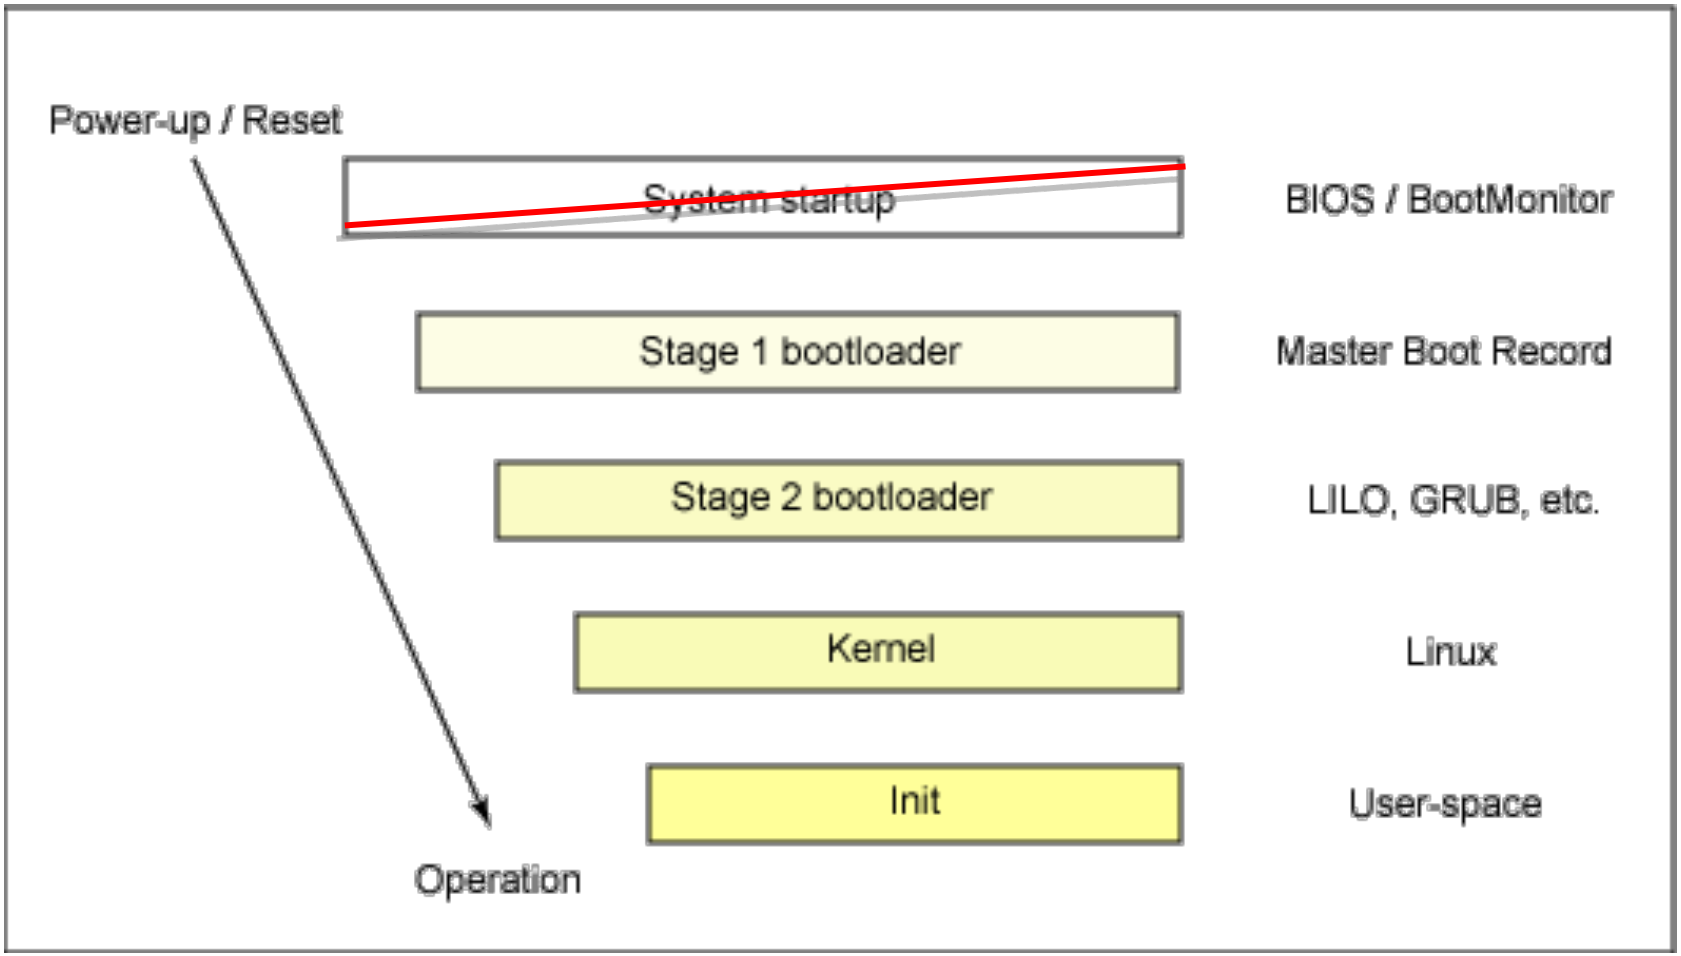

启动第三步——Boot Loader

- Boot Loader 就是在操作系统内核运行之前运行的一段小程序。通过这段小程序，可以初始化硬件设备、建立内存空间的映射图，从而将系统的软硬件环境带到一个合适的状态，以便为最终调用操作系统内核做好一切准备。

Boot loader

- Boot loader 也可以称之为操作系统内核加载器(OS kernel loader), 通常是严重地依赖于硬件而实现的。
- GRUB 和 LILO 最重要的Linux加载器，存放于MBR的bootloader区域。
  - Linux Loader（LILO）
  - GRand Unified Bootloader（GRUB）

LILO: LInux LOader

- *LInux LOader（LILO）* 已经成为所有 Linux 发行版的标准组成部分，是最老的 Linux 引导加载程序。
- 优点：它可以快速启动安装在主引导记录中的Linux操作系统。
- 局限：LILO 配置文件被反复更改时，主引导记录（MBR）也需要反复重写，但重写可能发生错误，这将导致系统无法引导。

GNU GRUB

- GNU GRand Unified Bootloader
  - 允许用户可以在计算机内同时拥有多个操作系统，并在计算机启动时选择希望运行的操作系统。

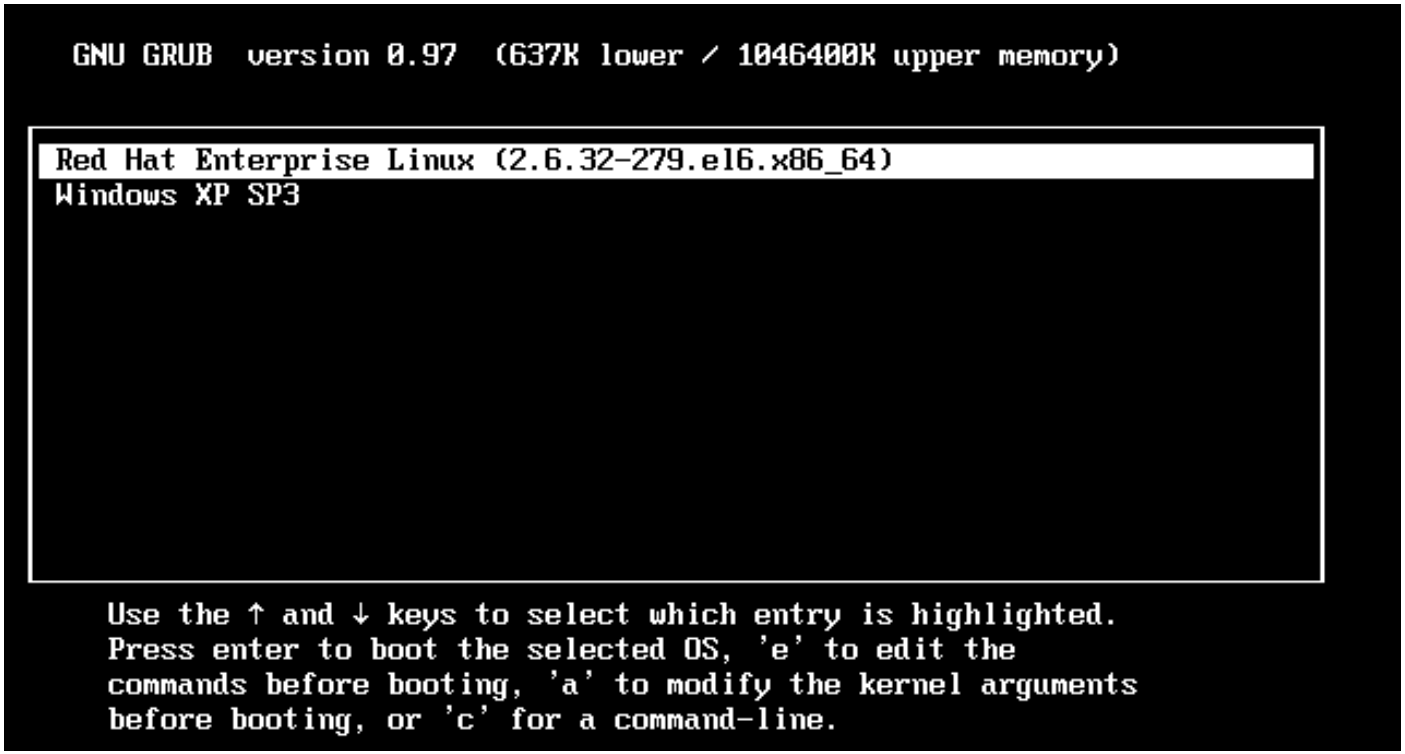

GRUB 与 LILO 的比较

- LILO 没有交互式命令界面，而 GRUB 拥有。
- LILO 不支持网络引导，而 GRUB 支持。
- LILO 将关于可以引导的操作系统位置的信息物理上存储在 MBR 中。如果修改了 LILO 配置文件，必须将 LILO 第一阶段引导加载 程序重写到 MBR。但错误配置的 MBR 可能会让系统无法引导。
- 使用 GRUB，如果配置文件配置错误，则只是默认转到 GRUB 命令行界面。

GRUB磁盘引导过程

- stage1: 读取磁盘第一个512字节（硬盘的0道0面1扇区，被称为MBR（主引导记录）,也称为bootsect。执行主引导程序，加载Stage 1.5到内存。
- Stage1.5: 识别各种不同的文件系统格式。这使得grub识别到文件系统（OS文件系统还没就绪）
- stage2: 加载系统引导菜单(/boot/grub/menu.lst或grub.lst)，加载内核映像(kernel image)到磁盘。
- 至此GRUB完成使命，内核开始接管。

MBR与引导扇区Boot Sector的关系

- MBR存放的位置是整个硬盘第一个扇区。
- Boot Sector是硬盘上每个分区的第一个扇区。

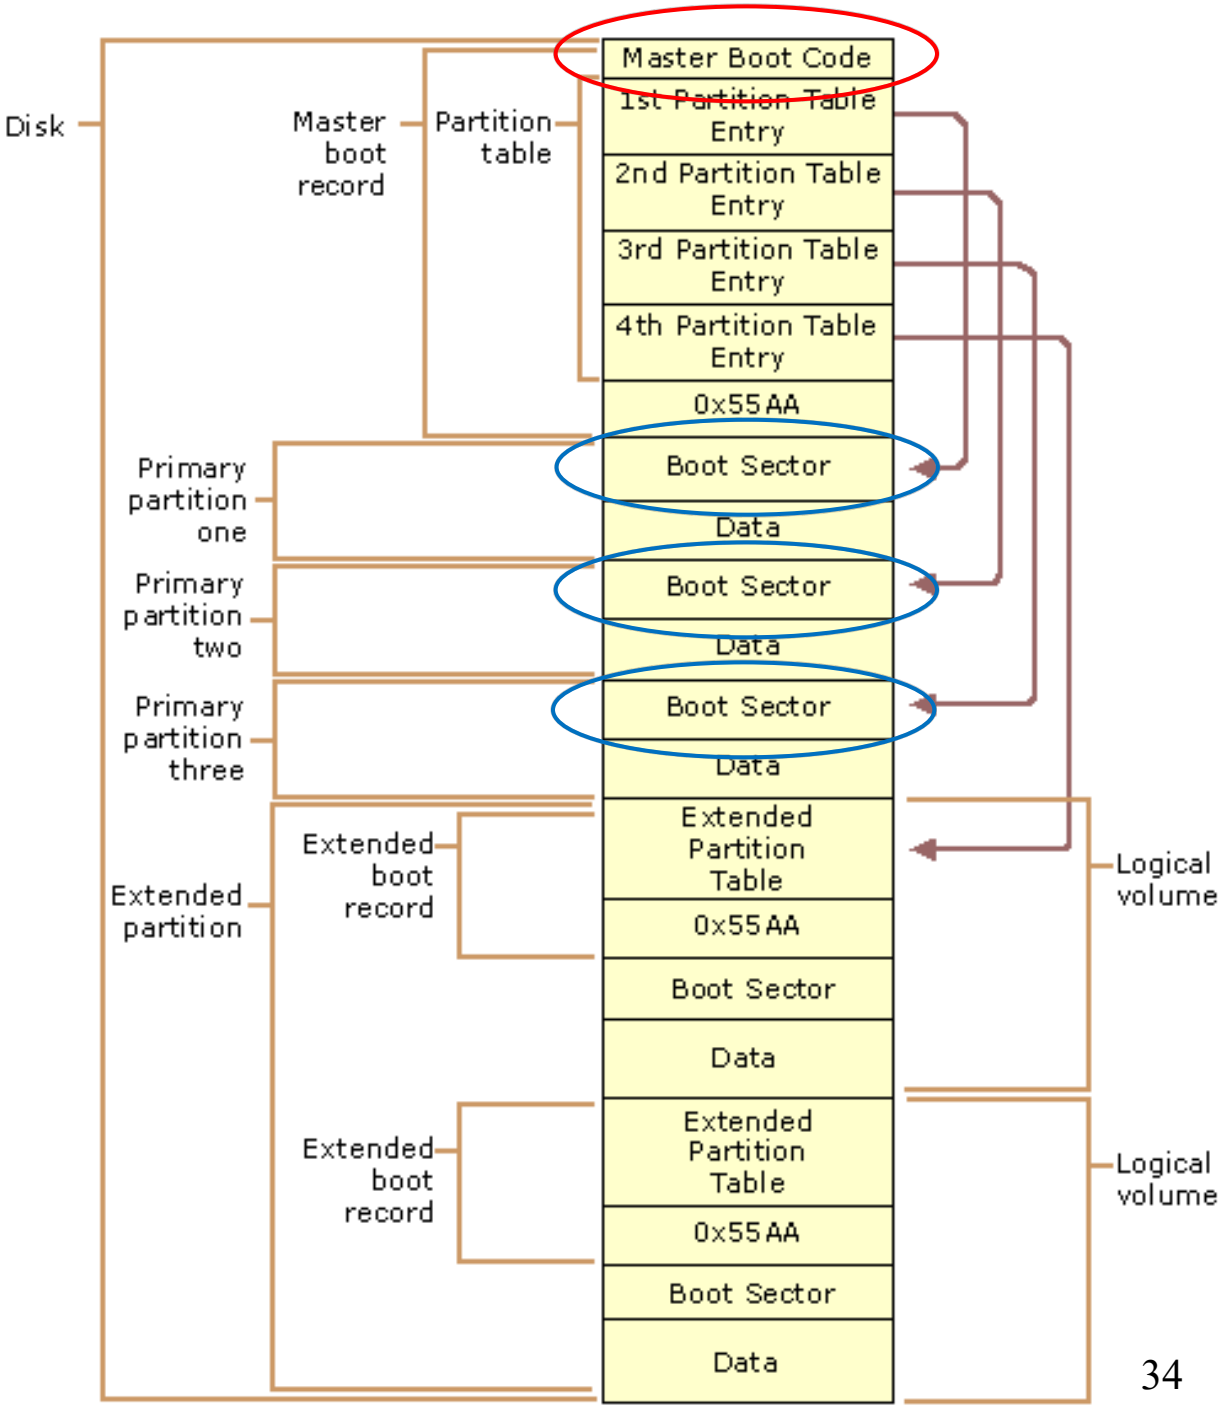

内核镜像

- 内核管理系统的资源，处理软硬件的通讯
- 内核常驻内存直到电脑关闭
- 内核镜像并不是一个可执行的内核，而是内核的压缩后的镜像
  - zImage ＜ 512 KB
  - bzImage ＞ 512 KB

Kernel Image

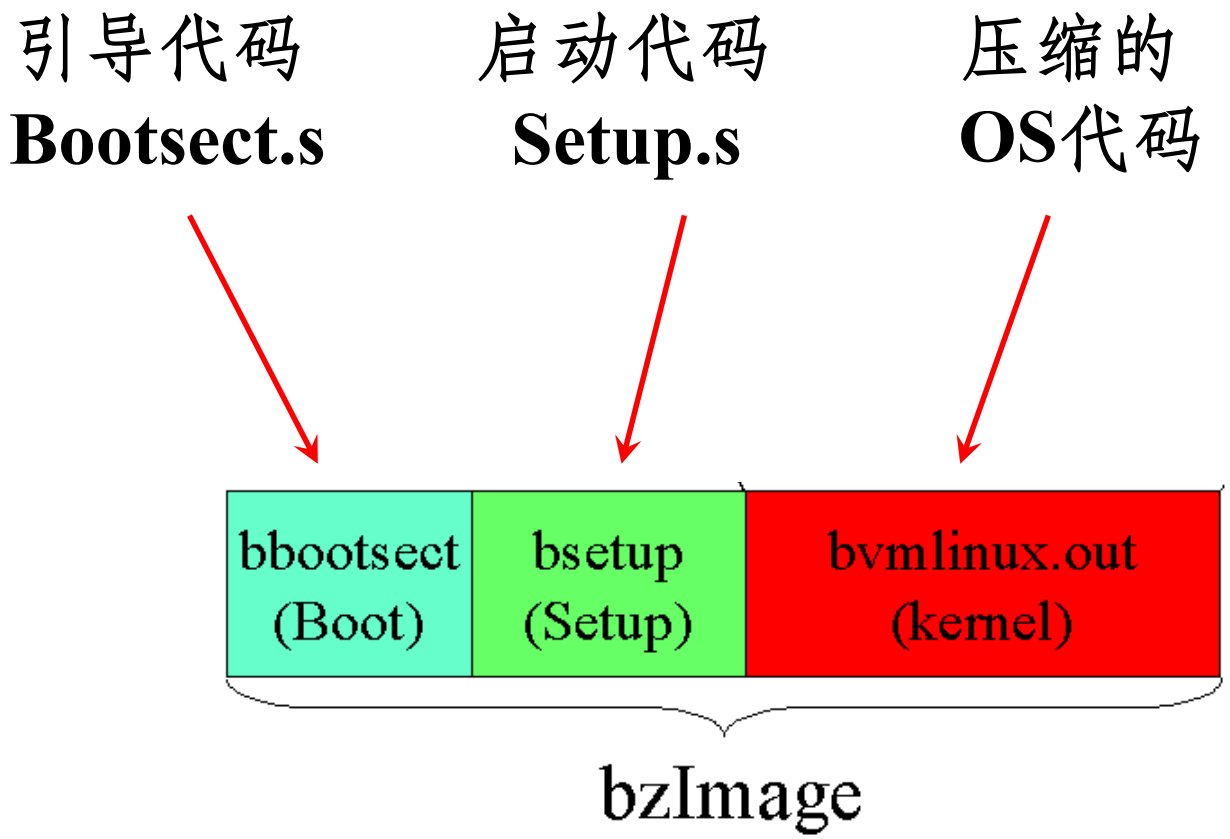

How Linux boot?

- 逐级引导、逐步释放灵活性

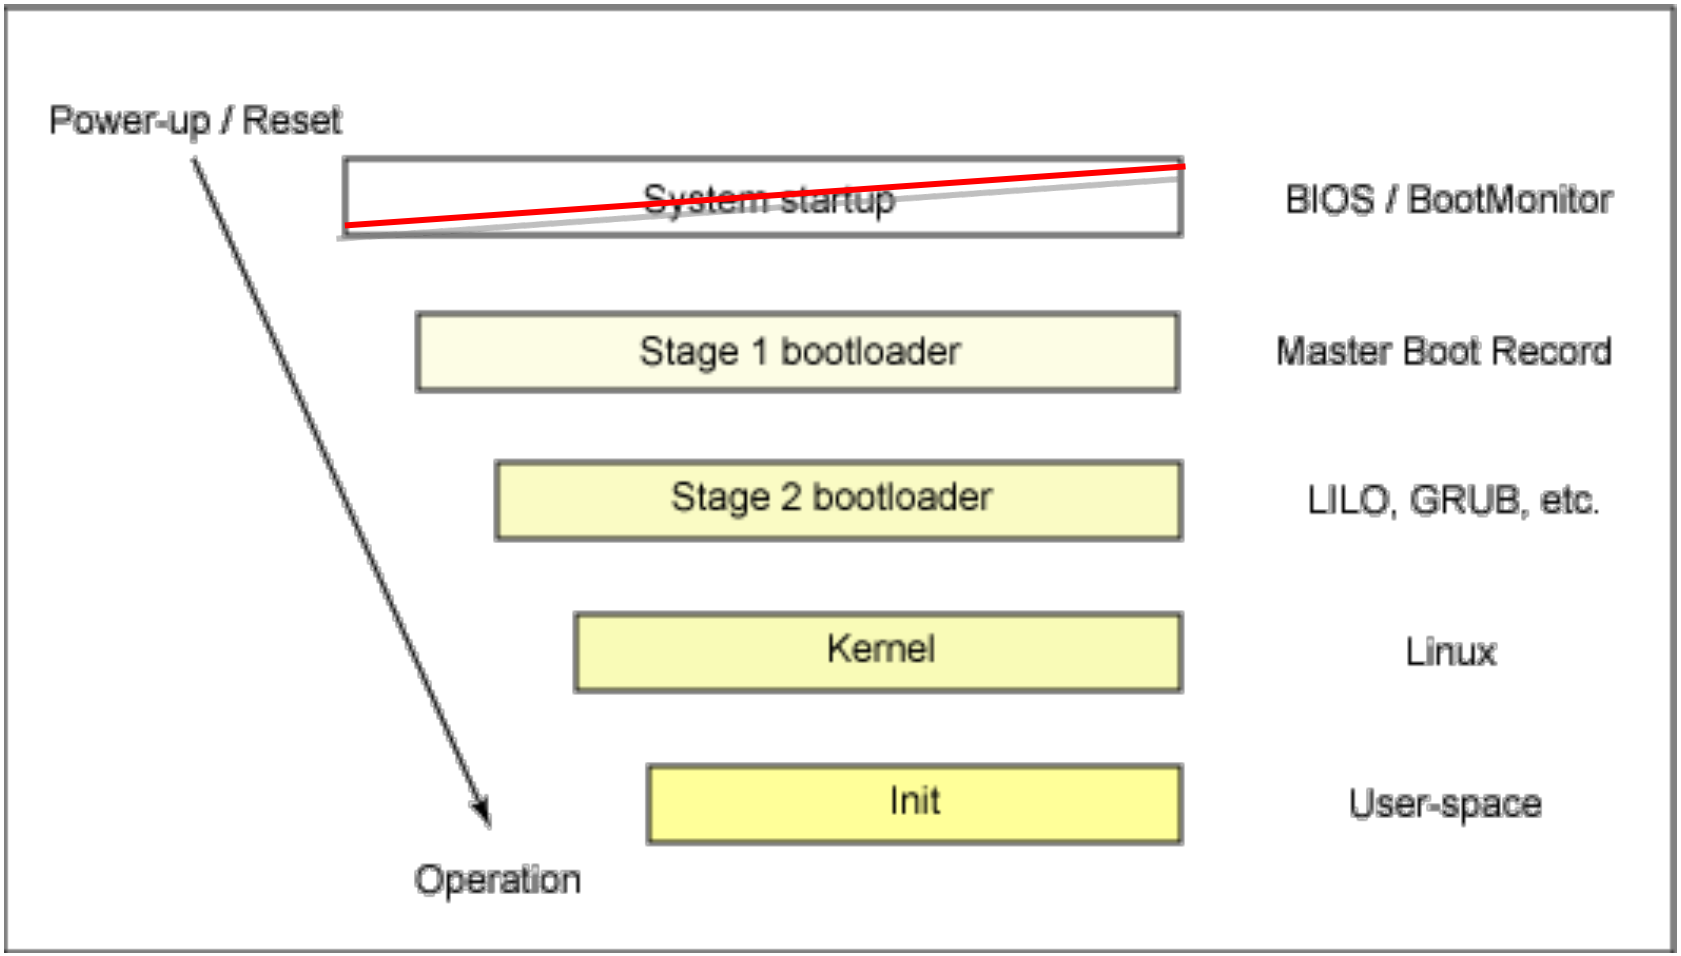

启动第四步——加载内核

- 根据grub设定的内核映像所在路径，系统读取内核映像，并进行解压缩操作。
- 系统将解压后的内核放置在内存之中，初始化函数并初始化各种设备，完成Linux核心环境的建立。

实模式和保护模式(X86)

- 实模式: 物理地址寻址
  - 8086 数据总线16位，地址总线20位
  - 一次最多取数据2^16=64K
  - 最大寻址2^20=1M系统内存
  - 只能支持单任务OS
- 保护模式：逻辑地址
  - 80286开始，可以寻址全部内存
  - 进程运行在独自受保护的地址空间，相互隔离
  - 支持多道程序设计（多任务系统）
  - 支持虚拟存储
- 为了向前兼容保留实模式
  - 80386（32位），奔腾，酷睿CPU都兼容实模式

Linux Kernel 加载过程

- 不断装载下一段可执行代码
  - 扇区拷贝
  - 支持文件系统
  - 设置内存
  - 解压缩
  - 切换CPU模式
  - …

https://en.wikipedia.org/wiki/Vmlinux

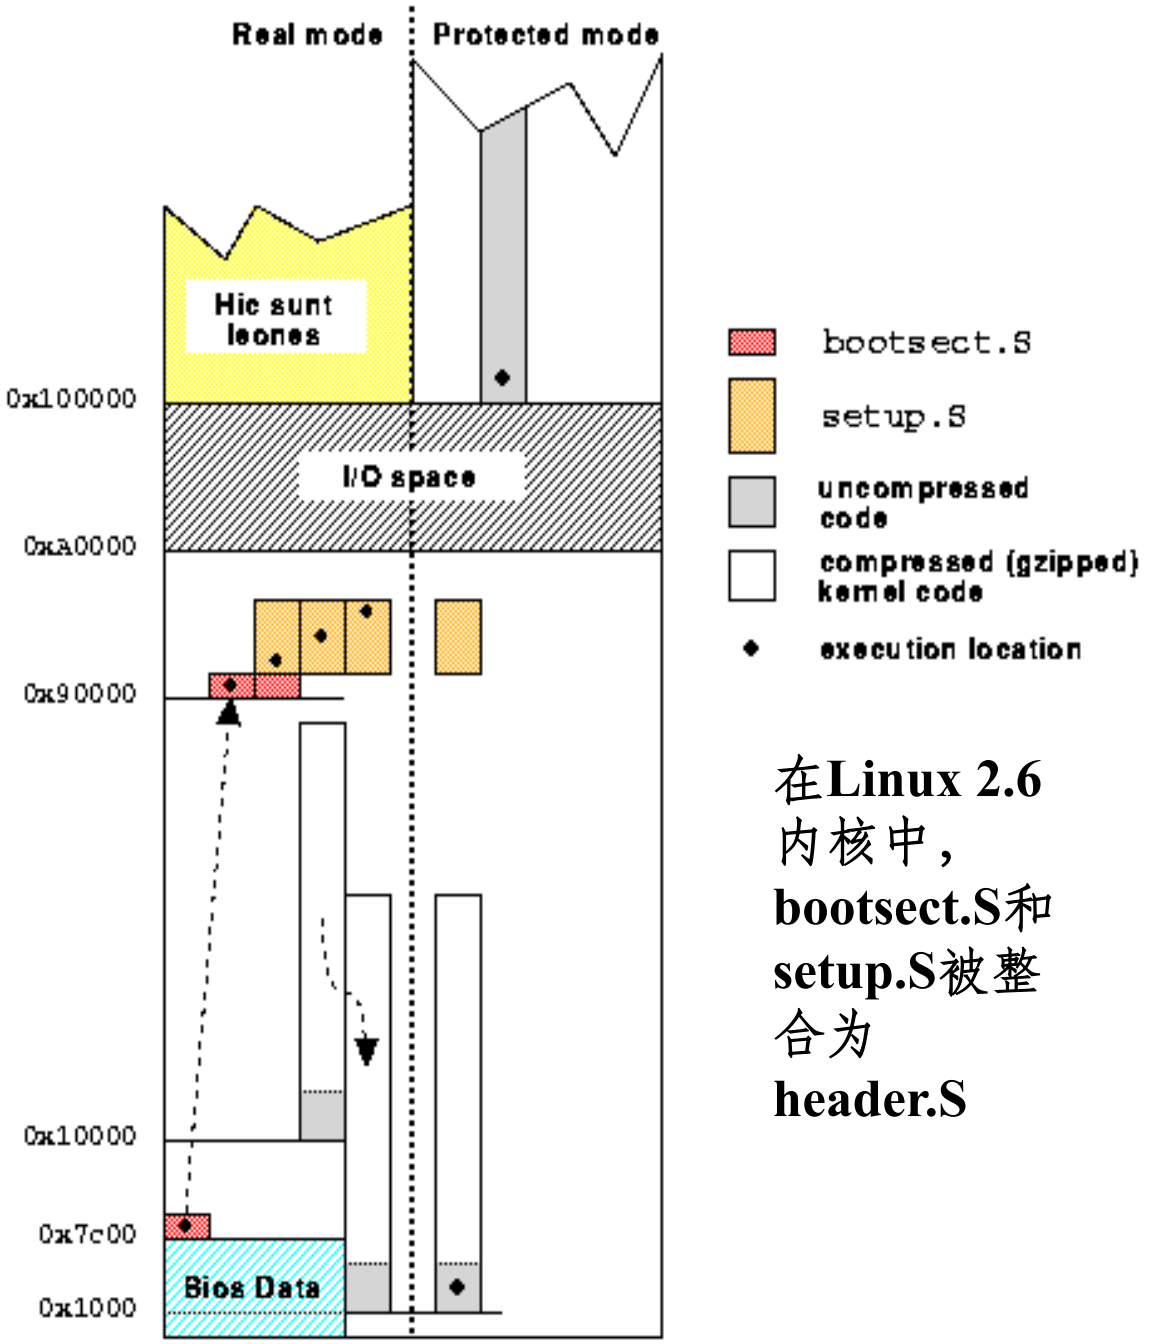

在Linux 2.6内核中，bootsect.S和setup.S被整合为header.S

Major functions flow for Linux kernel boot

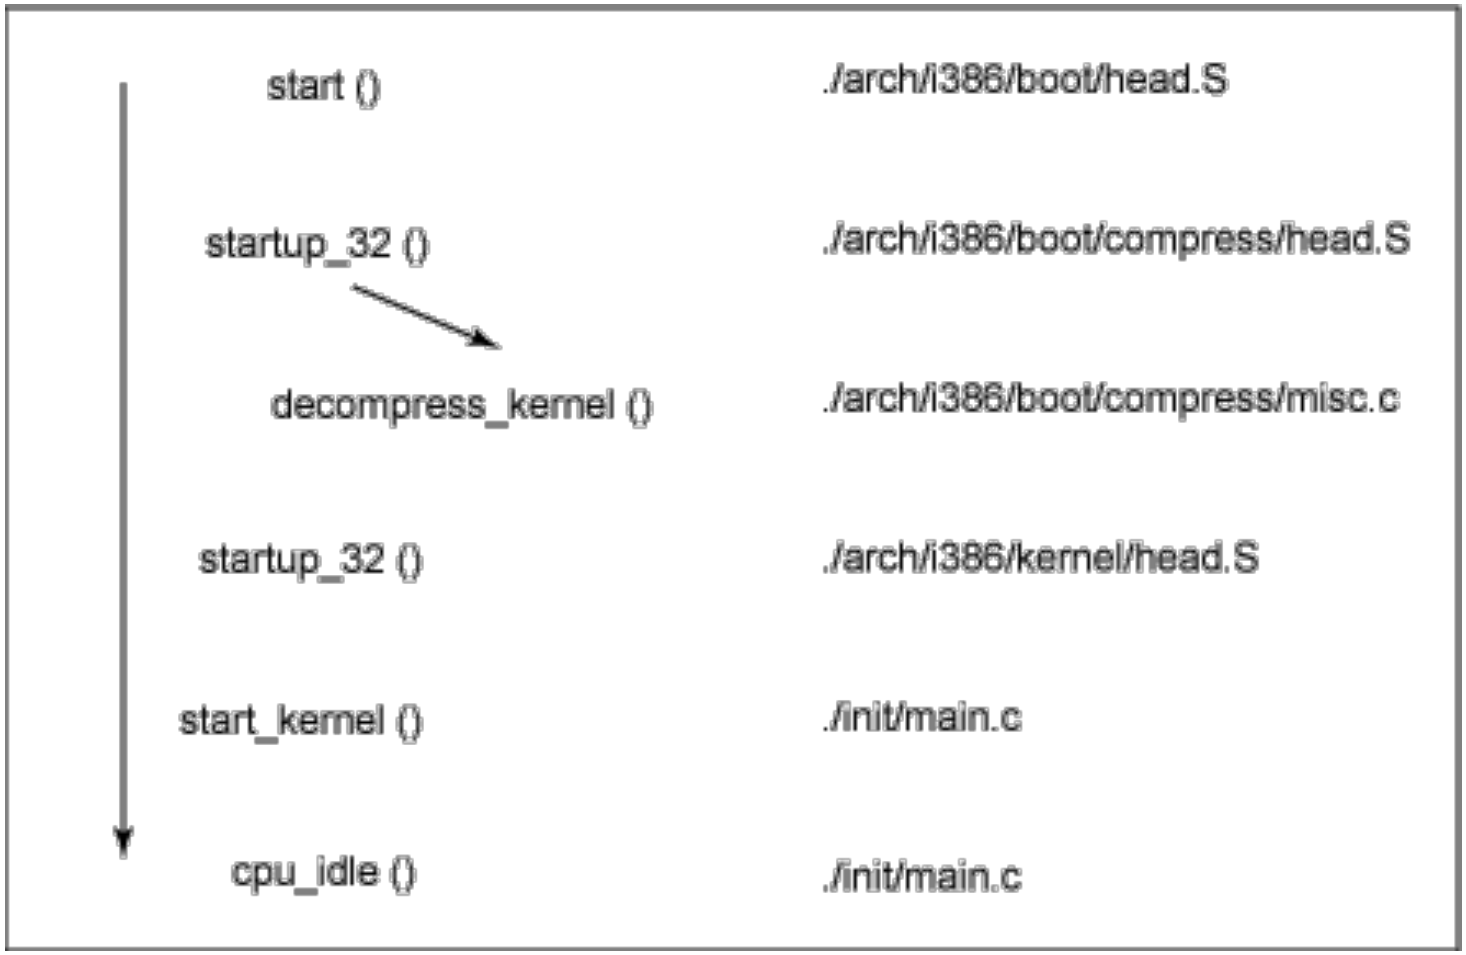

用于加载内核的关键文件

- bootsect.S :装载系统并设置系统启动过程的相关参数.
- setup.S　:初始化系统及硬件,并切换至保护模式.
- video.S　:初始化显示设备.

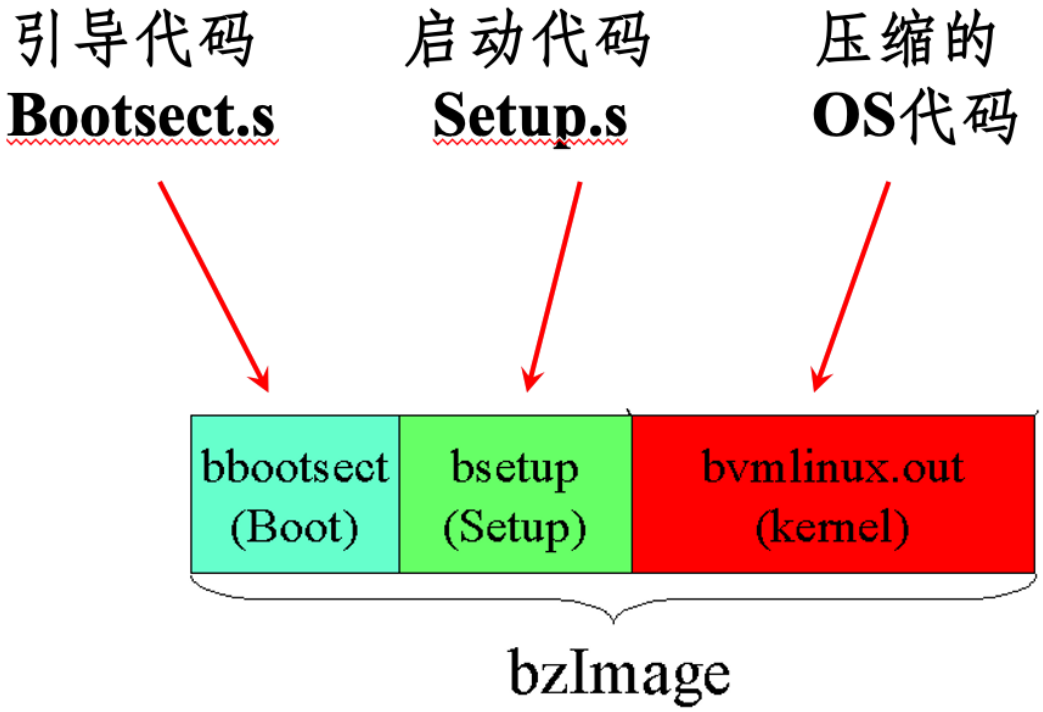

Bootsect.s

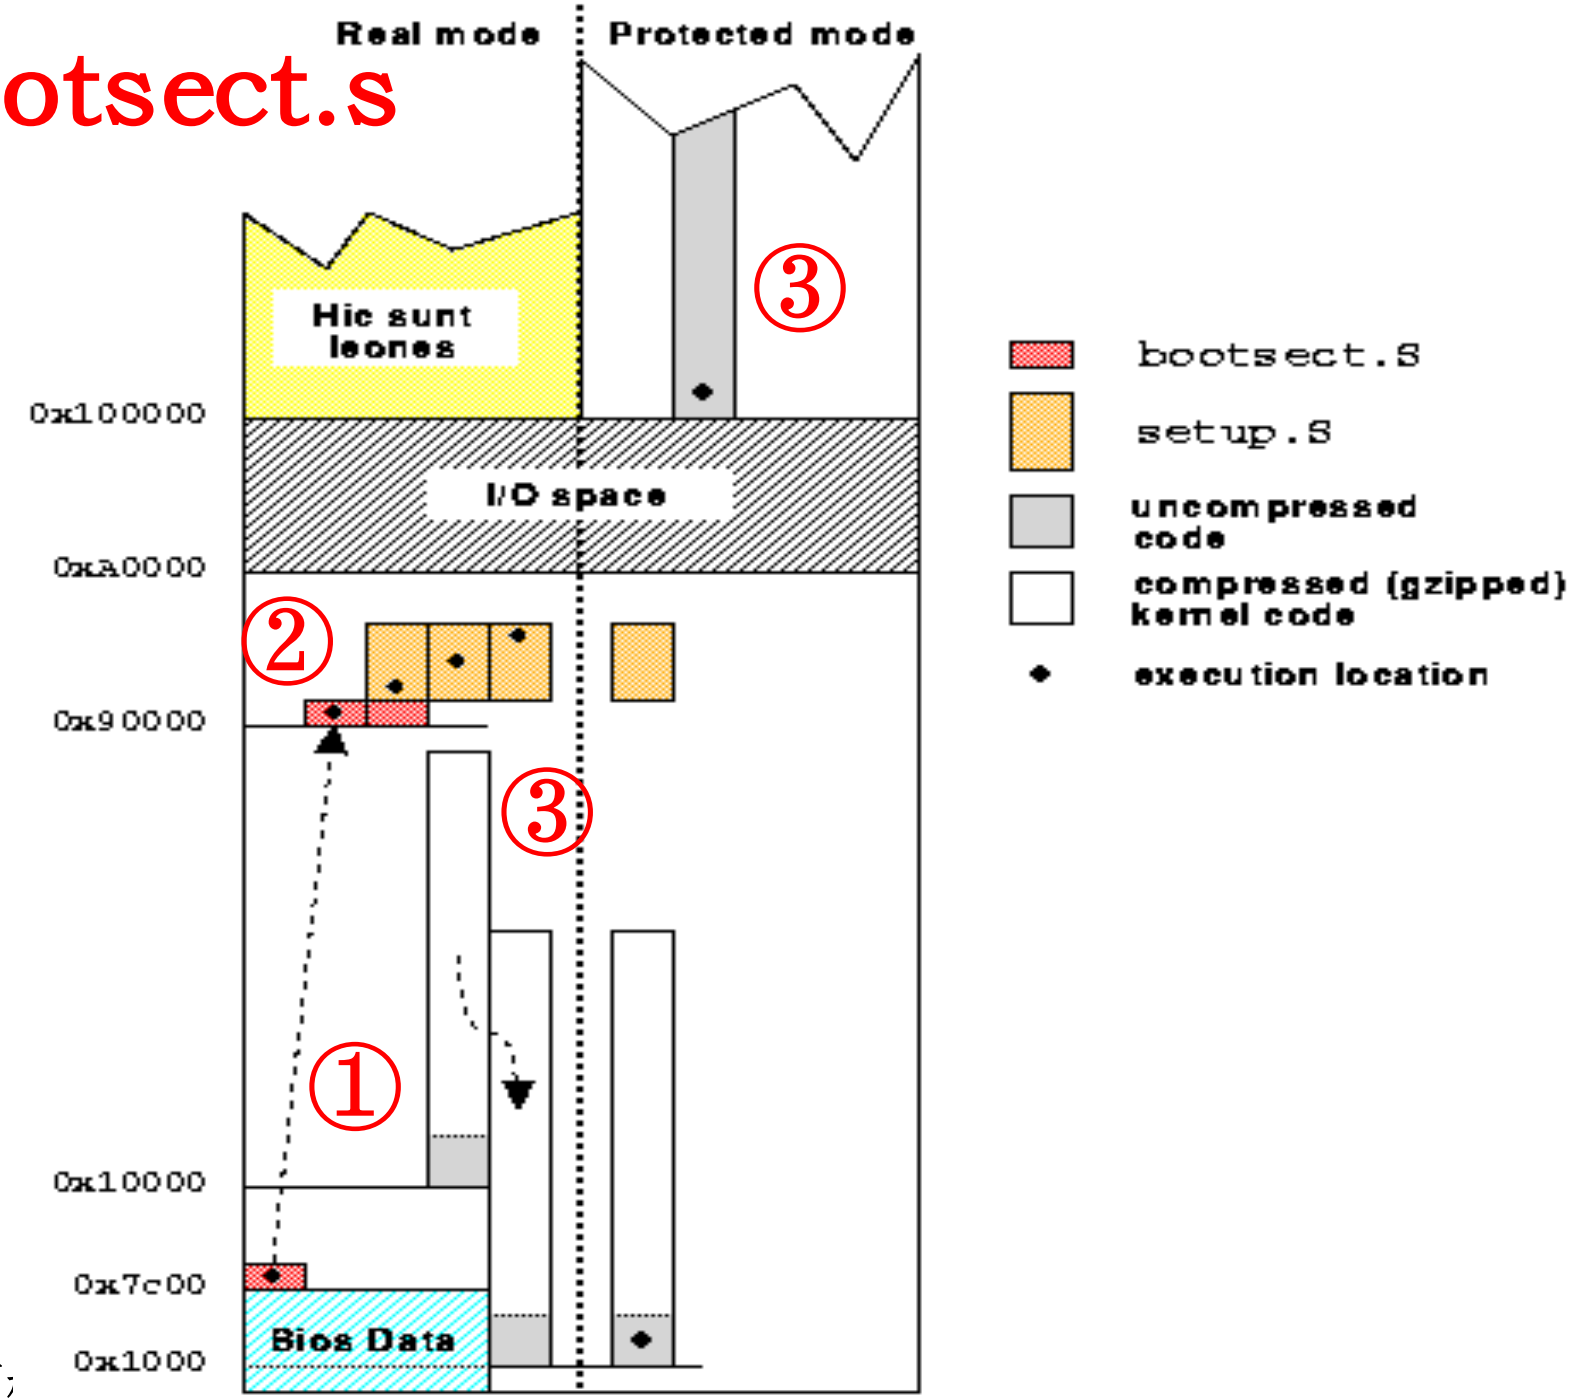
Real mode
Protected mode
Hic sunt leones
③
0x100000
I/O space
0xA0000
②
0x90000
③
①
0x10000
0x7c00
Bios Data
0x1000
bootsect.S
setup.S
uncompressed code
compressed (gzipped) kernel code
execution location

Bootsect.s

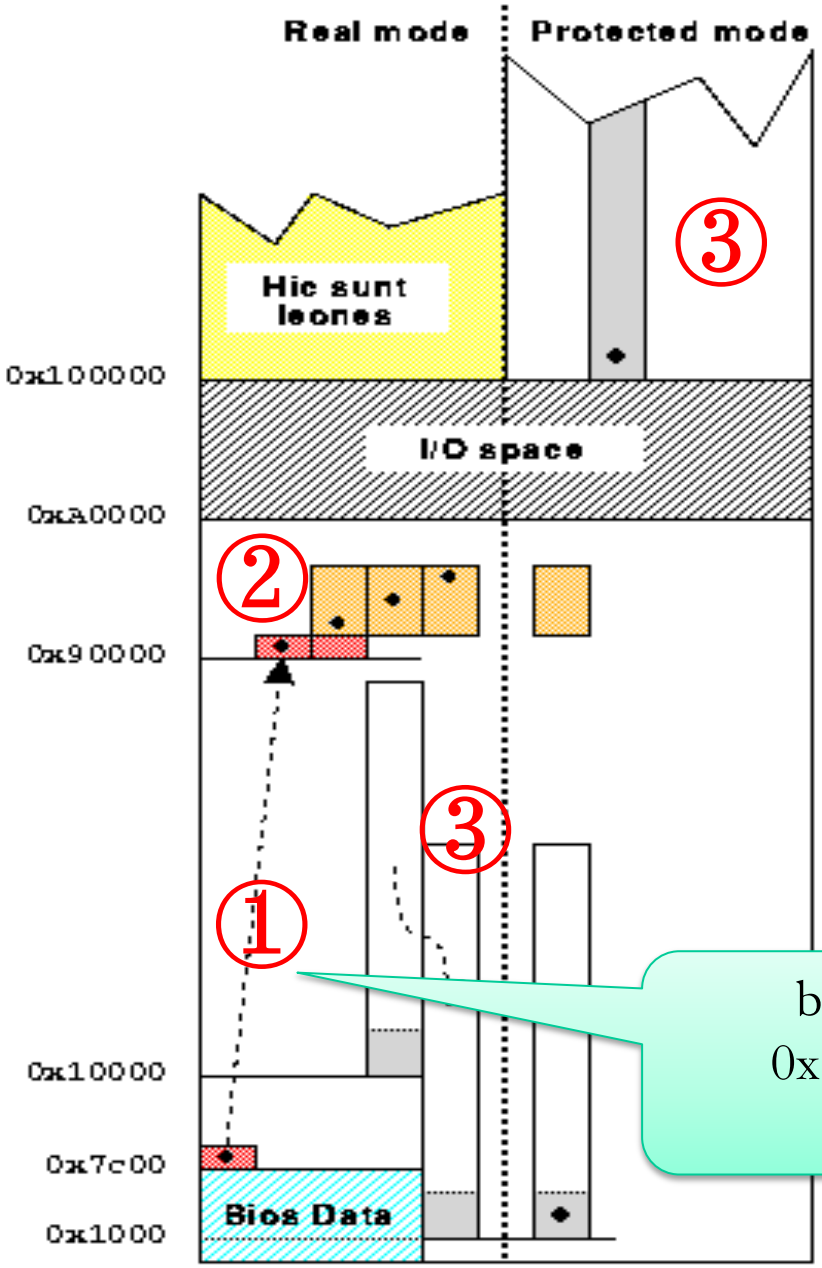

boot过程首先将自身从原始启动区0x7c00—0x7dff移至0x90000—0x901ff,并跳至下一条指令。

Bootsect.s

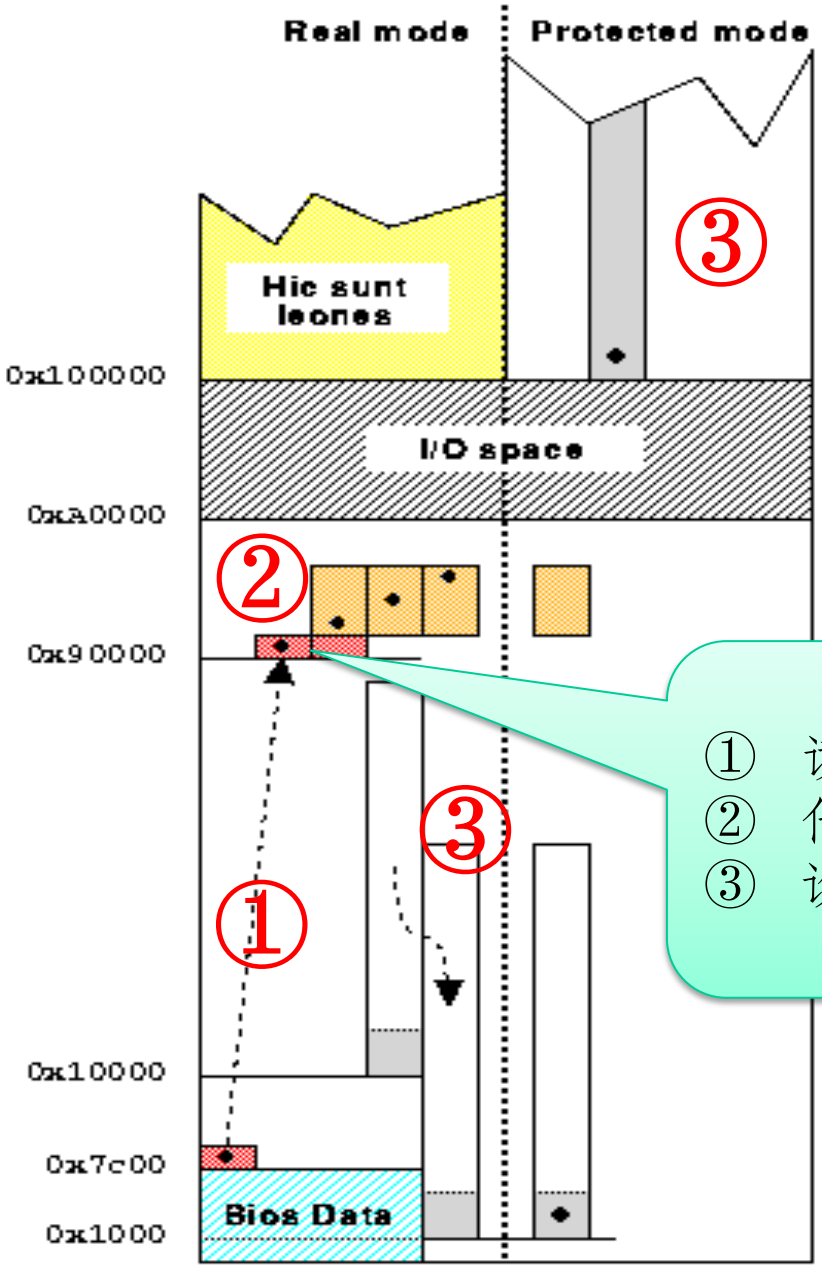

① 读引导扇区的后4个扇区到0x90200
② 代码主要调用引导阶段的函数，
③ 设置堆栈。

Bootsect.s

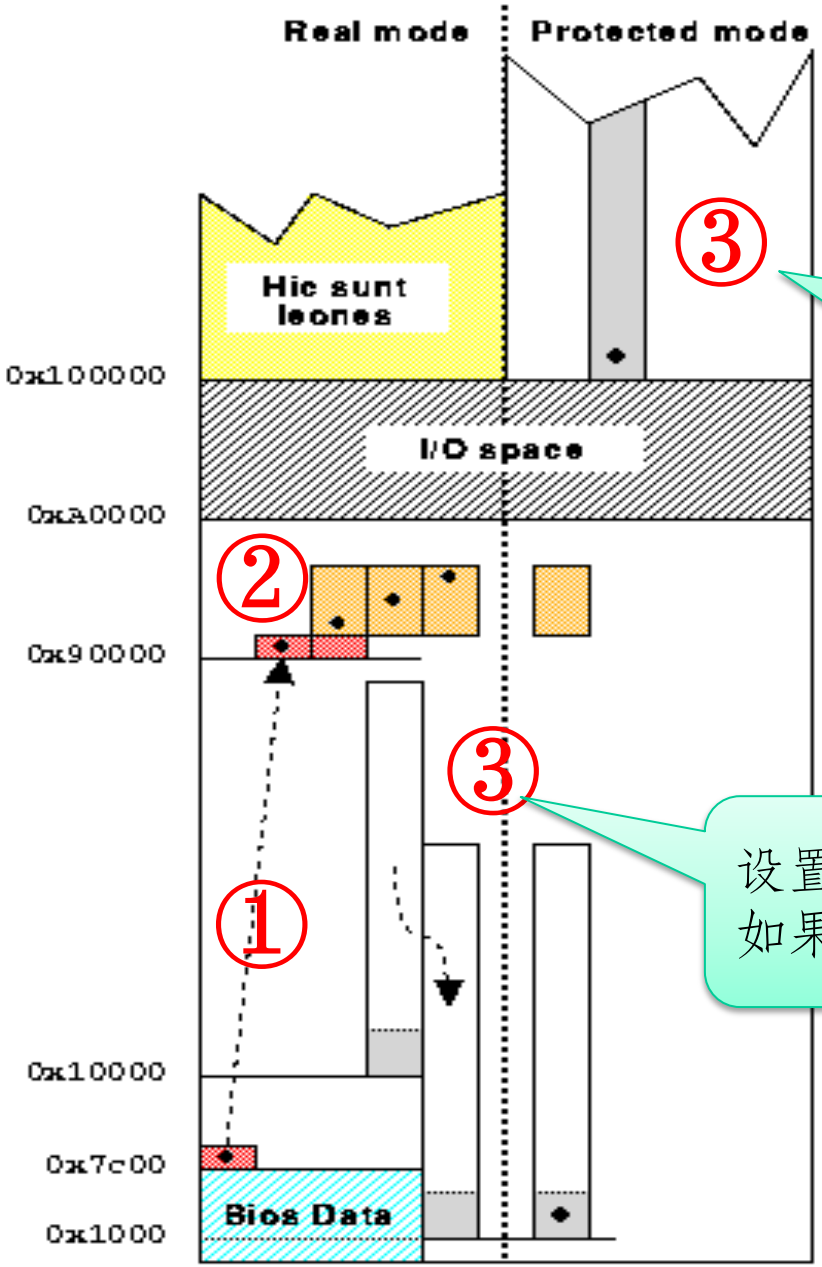

设置内核镜像：
如果是大内核，加载到0x100000（1M以上高端内存），

设置内核镜像：
如果是小内核，加载到0x10000（64K低端内存）

Bootsect.s

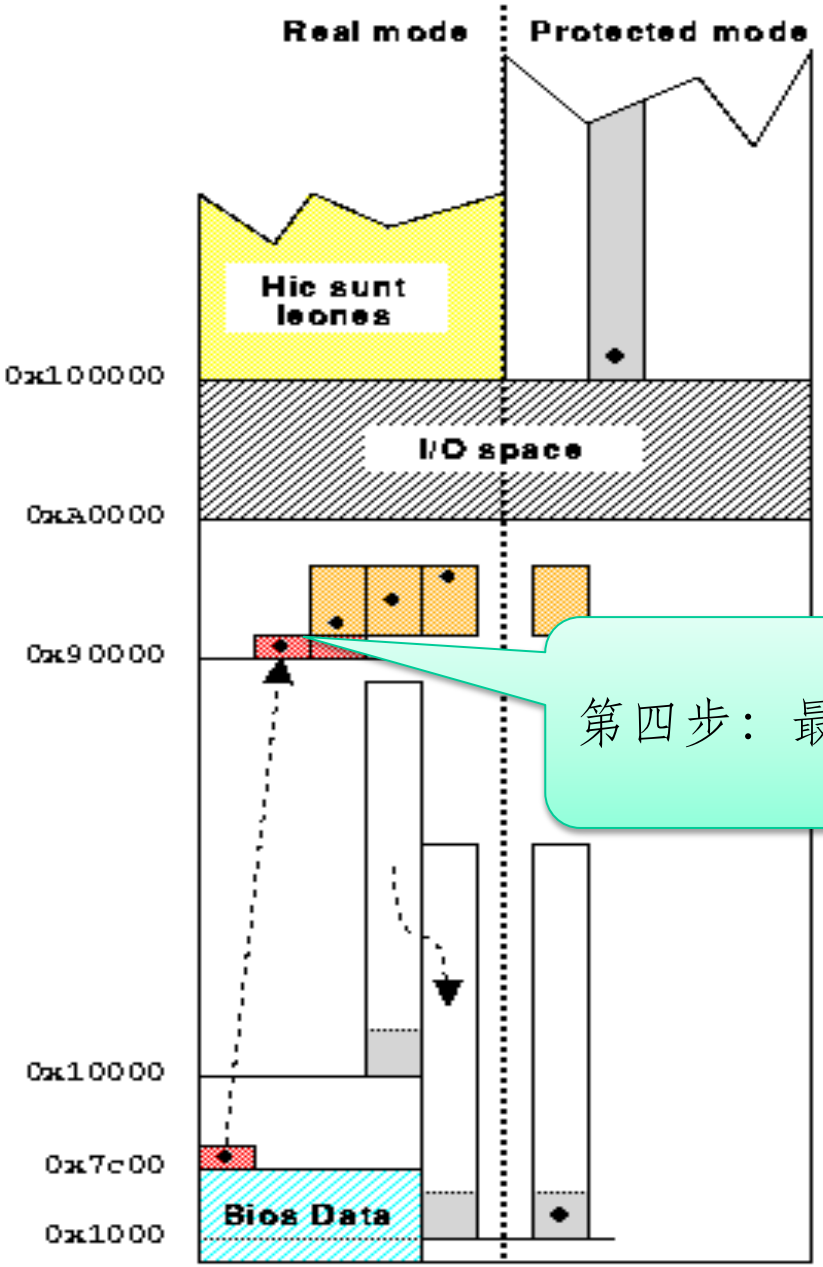

第四步：最终跳转到setup.S的入口

Setup.S

- 初始化硬件设备。如：调用BIOS例程建立描述系统物理内存布局的表；设置键盘的重复延迟和速率；初始化显卡；检测IBM MCA总线、PS/2鼠标设备、APM BIOS支持等……。
- 为内核程序的执行建立环境。如：启动位于8042键盘控制器的A20 pin。建立一个中断描述表IDT和全局描述表GDT表；重启FPU单元；对可编程中断控制器进行重新编程，屏蔽所有中断；设置CR0状态寄存器的PE位使CPU从实模式切换到保护模式，PG位清0，禁止分页功能等……；
- 跳转到startup_32()汇编函数, jmpi 0x100000, __BOOT_CS，终于进入内核Head.S；

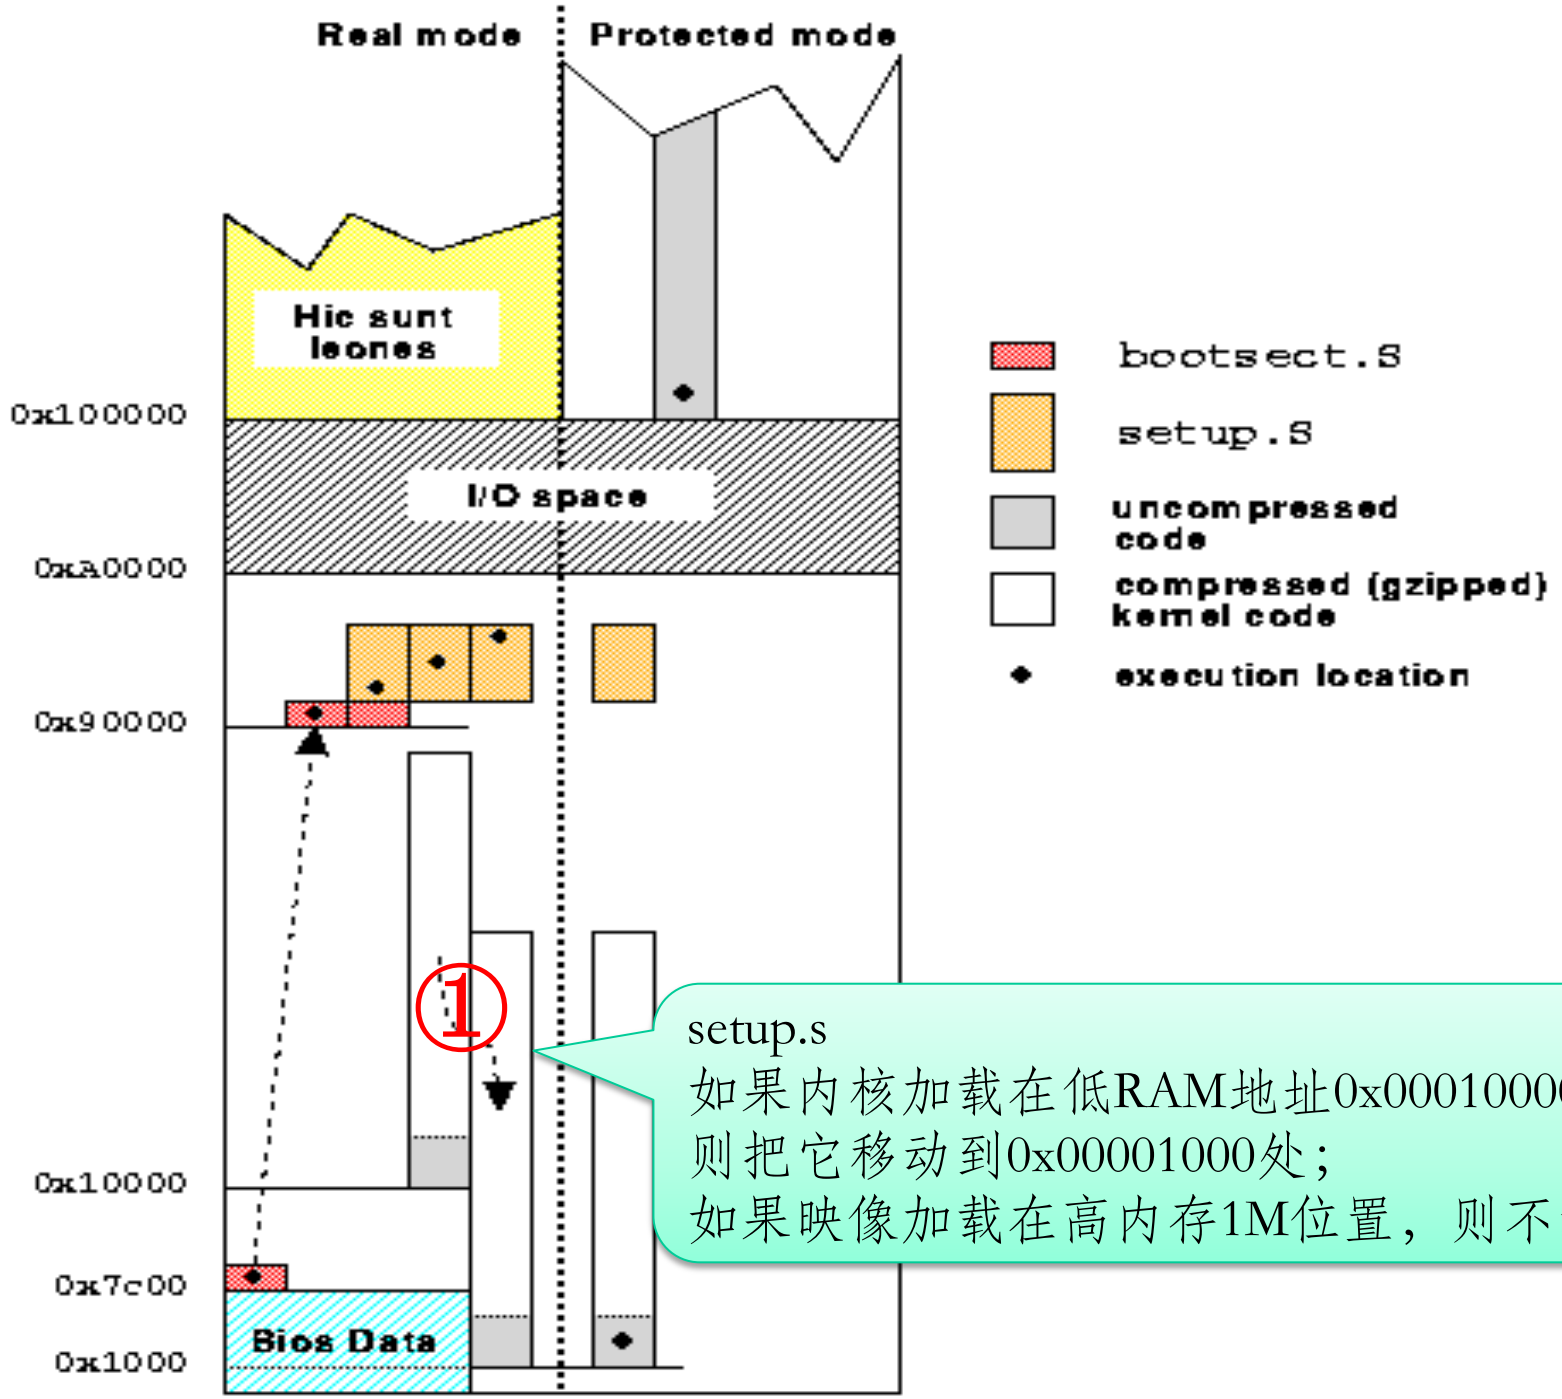

setup.s
如果内核加载在低RAM地址0x00010000，则把它移动到0x00001000处；
如果映像加载在高内存1M位置，则不动

Head.S（第一个start_32()函数）

setup结束后，该函数被放在0x00001000或者0x00100000位置，该函数主要操作：

- 首先初始化段寄存器和临时堆栈；
- 清除eflags寄存器的所有位；
- 将_edata和_end区间的所有内核未初始化区填充0；

① 调用decompress_kernel( )函数解压内核映像。首先显示“Uncompressing Linux...”信息，解压完成后显示“OK, booting the kernel.”。

- 跳转到0x00100000物理内存处执行；

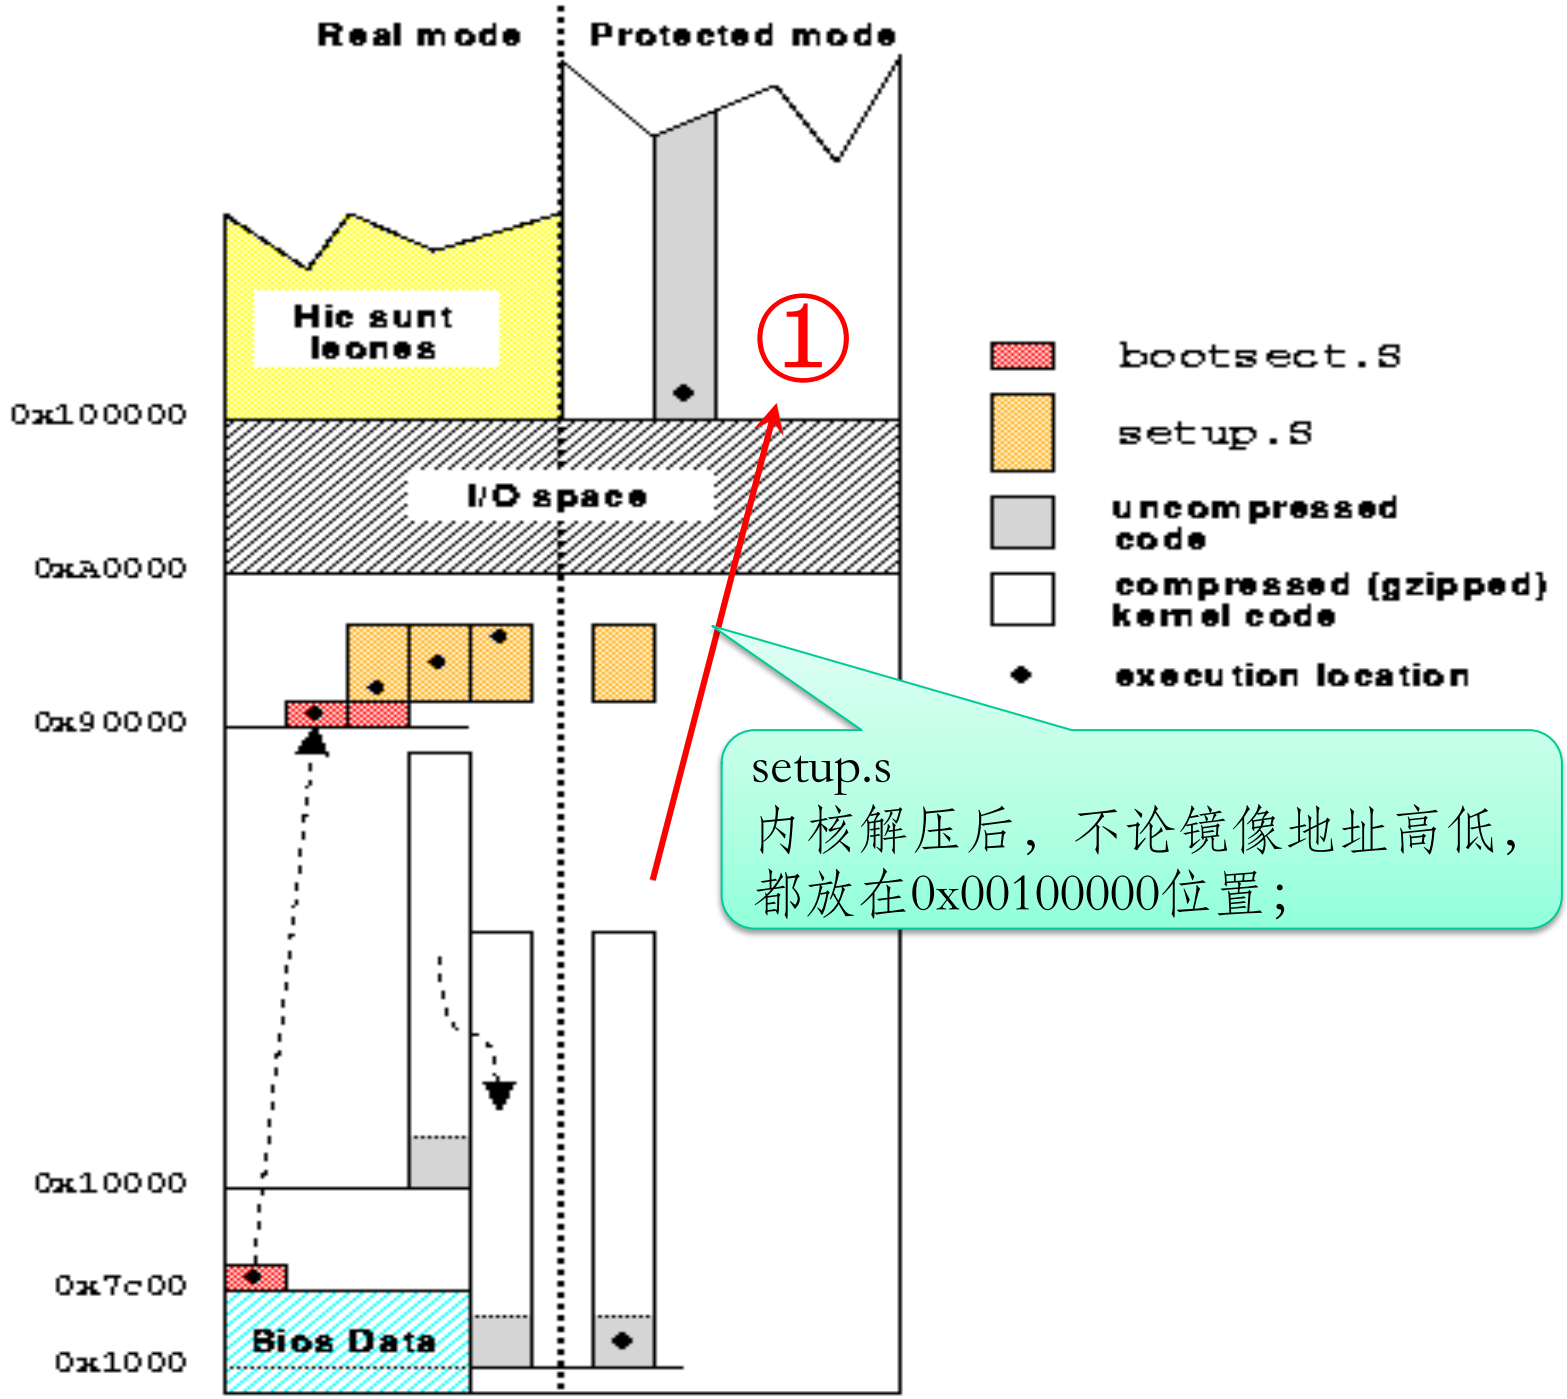
Real mode
Protected mode
Hic sunt leones
0x100000
I/O space
0xA0000
0x90000
0x10000
0x7c00
Bios Data
0x1000
①
bootsect.S
setup.S
uncompressed code
compressed (gzipped) kernel code
execution location
setup.s
内核解压后，不论镜像地址高低，
都放在0x00100000位置；

Head.S（第二个start_32()函数）

- 解压后的映像开始于arch/i386/kernel/head.S 文件中的startup_32()函数，因为通过物理地址的跳转执行该函数的，所以相同的函数名并没有什么问题。该函数为Linux第一个进程建立执行环境，操作如下：
  a) 初始化ds,es,fs,gs段寄存器的最终值；
  b) 用0填充内核bss段；
  c) 初始化swapper_pg_dir数组和pg0包含的临时内核页表
  d) 建立进程0idle进程的内核模式的堆栈；
  ……
  x) 跳转到start_kernel函数，这个函数是第一个C编制的函数，内核又有了一个新的开始。

调用Start_kernel()

- 调用start_kernel()函数来启动一系列的初始化函数并初始化各种设备，完成Linux核心环境的建立：
  - 调度器初始化，调用sched_init();
  - 调用build_all_zonelists函数初始化内存区；
  - 调用page_alloc_init()和mem_init()初始化伙伴系统分配器；
  - 调用trap_init()和init_IRQ()对中断控制表IDT进行最后的初始化；
  - 调用softirq_init() 初始化TASKLET_SOFTIRQ和HI_SOFTIRQ；
  - Time_init()对系统日期和时间进行初始化；
  - 调用kmem_cache_init()初始化slab分配器；
  - 调用calibrate_delay()计算CPU时钟频率；

至此，Linux内核已经建立起来了，基于Linux的程序应该可以正常运行了。

启动第五步——用户层init依据inittab文件来设定运行等级

- 内核被加载后，第一个运行的程序便是/sbin/init，该文件会读取/etc/inittab文件，并依据此文件来进行初始化工作。
- /etc/inittab文件最主要的作用就是设定Linux的运行等级，其设定形式是“：id:5:initdefault:”，这就表明Linux需要运行在等级5上。

Linux的运行等级

Linux的运行等级设定如下：

- 0：关机
- 1：单用户模式
- 2：无网络支持的多用户模式
- 3：有网络支持的多用户模式
- 4：保留，未使用
- 5：有网络支持有X-Window支持的多用户模式
- 6：重新引导系统，即重启

启动第六步－－init进程执行rc.sysinit

- 在设定了运行等级后，Linux系统执行的第一个用户层文件就是/etc/rc.d/rc.sysinit脚本程序，它做的工作非常多，包括设定PATH、设定网络配置（/etc/sysconfig/network）、启动swap分区、设定/proc等等。
- 如果你有兴趣，可以到/etc/rc.d中查看一下rc.sysinit文件，非常复杂。

启动第七步－－启动内核模块

- 具体是依据/etc/modules.conf文件或/etc/modules.d目录下的文件来装载内核模块。

启动第八步－－执行不同运行级别的脚本程序

- 根据运行级别的不同，系统会运行**rc0.d**到**rc6.d**中的相应的脚本程序，来完成相应的初始化工作和启动相应的服务。

启动第九步－－执行/etc/rc.d/rc.local

- 你如果打开了此文件，里面有一句话，读过之后，你就会对此命令的作用一目了然：

  # This script will be executed *after* all the other init scripts.

  # You can put your own initialization stuff in here if you don't

  # want to do the full Sys V style init stuff.

- **rc.local**就是在一切初始化工作后，**Linux**留给用户进行个性化的地方。你可以把你想设置和启动的东西放到这里。

启动第十步－－执行/bin/login程序，进入登录状态

- 此时，系统已经进入到了等待用户输入**username**和**password**的时候了，你已经可以用自己的帐号登入系统了。

漫长的启动过程结束了.

其实在这背后，还有着更加复杂的底层函数调用，等待着你去研究……

课堂上的内容就算抛砖引玉了

结合实验

- 阅读《See MIPS Run》，了解MIPS启动过程
- 查阅资料，了解ARM（树莓派）启动过程

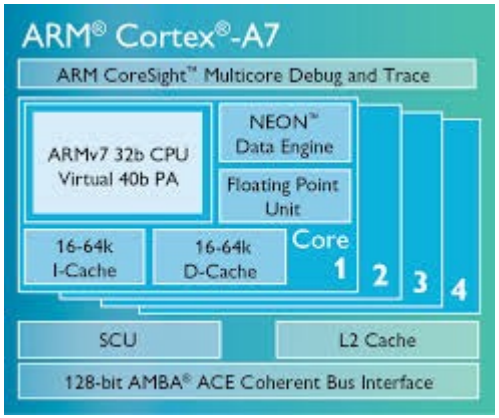

思考：为什么操作系统启动慢

- 写一个不少于1页A4纸的调研报告
- 给出对OS启动过程的分析，指出最耗时的启动过程是什么？
- 现有的优化措施有哪些？
- 思考并给出你的优化建议。